肝脏超声包虫病识别：阶段进展与模型对比

高子淇 · 2026 年 9 月 28 日

阶段摘要

已完成公开数据整理、概率预测 Agent 搭建和 GLM / DeepSeek 两模型的 10 组真实运行对照，形成了可复查的实验与评价流程。最新两模型对照中，GLM 在共同有效样本上的最高准确率为 90.59%；参考图增强在两模型上均改善了 log loss，为后续方法选择提供了初步依据。

1. 研究目标与已完成工作

面向肝脏超声图像，输出患包虫病的估计概率及简短影像依据；比较不同大模型，以及参考图、医学知识与选择性复核对识别效果的影响。当前工作以公开数据上的方法探索为主。

- **数据整理：** 汇集 HE_DCNN、Bioengineering 论文补充材料及公开网页 / 数据仓库中的超声图像，整理出 219 张有标签图片（105 阳性、114 阴性）。完成统一命名、标签映射和来源记录；未标注或标签不明的图片单独存放。当前固定参考图为 8 张（4 阳性、4 阴性），其余 211 张用于开发评价。
- **实验框架：** 实现基础版、参考图增强、医学知识增强和二者组合四种模式，统一输出患病概率；模型接口与 Agent 流程解耦，保存预测、真值、调用用量和错误记录。完成 GLM 与 DeepSeek 的实际调用及匹配配置对照。
- **方法迭代：** 探索参考图和医学知识两种增强方式，根据漏判与误报分析，调整参考图来源和类别组成，实验最佳参考图数量，优化医学提示词，并实现“初判＋选择性复核”：仅复核概率位于指定区间的初判阴性样本。通过离线阈值扫描，已形成各版本在当前开发集上的判定阈值和复核阈值候选。另外，初步探索包虫病专家模型辅助方案，已完成部分离线技术验证，但受数据量与可靠性限制，尚未纳入主流程。

2. 主要阶段发现

- **参考图是目前较有依据的增强方向：** 在同一 202 张共同有效图像上，相比各自基础版，8 张参考图使 GLM 和 DeepSeek 的 Log loss 分别下降 17.66% 和 18.61%。
- **复核需要按模型控制范围：** GLM 的复核区间 (0.1,0.3) 在同一运行的 210 张配对有效图上，纠正 8 次漏判、新增 2 次误报，净增加 6 次正确预测，额外调用 47 次。DeepSeek 的阴性复核尚未显示准确率净收益。
- **医学知识提示词效果并不理想：** 多次 GLM 试验中，加入较长医学规则未显示稳定增益，已尝试弱化规则和精简表述，相比详细知识版上观察到改善，但与无知识版相比仍未表现出稳定增益。

3. 历史实验与方案演变（GLM）

3.1 参考图数量与来源实验

参考池最初为 44 张（42 阳性、2 阴性，实际仅发送 4 张），后缩为 8 张（4 阳性、4 阴性），并调整阳性来源，减轻类别与来源绑定。下表以两轮相同输入配置的单次推理为例，在同一 201 张共同有效图上评分（93 阳性、108 阴性）。

配置	第 1 轮 loss	第 2 轮 loss	平均 loss	阈值 t	平均准确率
基础版（0 张）	0.4977	0.5128	0.5052	0.18	91.04%
参考图 4 张	0.4591	0.4618	0.4605	0.25	87.81%
参考图 6 张	0.4305	0.4264	0.4285	0.20	88.06%
参考图 8 张	0.4292	0.4207	0.4249	0.25	88.56%

两轮均观察到参考数从 4 增至 8 时 loss 下降，支持保留 8 图作为概率预测候选。

3.2 医学知识增强与提示词精简

从 11 份文献材料整理医学背景，依次尝试较长规则、弱化规则措辞、精简背景。下表比较各轮四种模式的 Log loss。注：仅能在同一行内比较。

医学提示词	共同图数	基础版	参考版	知识版	参考＋知识
v2：较长医学规则	48	0.3624	0.3284	0.3988	0.3699
v3：弱化规则措辞	48	0.4230	0.3305	0.4028	0.3981
v4：精简医学背景	201	0.4977	0.4292	0.5414	0.4596

可见几版医学知识提示词下，两种知识增强未优于各自对照。

3.3 阈值、重复运行与复核探索

在上述 201 张上，基础版以相同候选 t=0.15 或 0.18 重评分，两次准确率为 92.04% 与 90.05%，平均 91.04%。首次尝试复核，6 个配置有 4 个 loss 变差。随后改用中性提示词，后续试验中 8 图＋复核 (0.05,0.2) 的概率评分最好（loss=0.4116、Brier=0.1320）。

4. 两模型对照结果

比较 glm-5.3-flash 与 deepseek-flash，每模型 5 种配置、每配置 1 次运行。各组使用相同的 211 张图像与顺序；参考版使用同一组 8 张参考图。为统一分母，下表仅纳入十组均有有效概率的 202 张图像（98 阳性、104 阴性）。

模型	配置	t	准确率	Log loss ↓	Brier ↓	AUC ↑	FN / FP
GLM	基础版	0.18	90.59%	0.5207	0.1758	0.9453	11 / 8
GLM	参考图 8 张	0.25	89.60%	0.4288	0.1379	0.9516	9 / 12
GLM	参考图＋复核 (0.1,0.3)	0.30	89.60%	0.4126	0.1329	0.9577	9 / 12
GLM	参考图＋复核 (0.05,0.3)	0.30	87.13%	0.4487	0.1478	0.9403	9 / 17
GLM	参考图＋复核 (0,0.3)	0.30	88.12%	0.4451	0.1463	0.9429	9 / 15
DeepSeek	基础版	0.18	65.84%	0.7218	0.2550	0.7118	23 / 46
DeepSeek	参考图 8 张	0.25	65.35%	0.5875	0.2019	0.7684	12 / 58
DeepSeek	参考图＋复核 (0.1,0.3)	0.30	63.37%	0.6159	0.2157	0.7318	4 / 70
DeepSeek	参考图＋复核 (0.05,0.3)	0.30	60.89%	0.6445	0.2278	0.7237	9 / 70
DeepSeek	参考图＋复核 (0,0.3)	0.30	63.86%	0.6448	0.2288	0.7256	9 / 64

t 为分类阈值（p≥t 判阳性）；复核 (a,b) 指仅对 a<p初判<b 的样本再次判断，b 同时为该组分类阈值。不同模式原 t 不同，准确率差异不能全部归因于增强方法。Log loss、Brier 越低越好，AUC 越高越好；FN / FP 为按当前标签计的漏判 / 误报数。

GLM 在 5 对匹配配置的概率评分和 AUC 上均优于 DeepSeek；其中基础版分类准确率最高，参考图＋复核 (0.1,0.3) 的概率评分最佳（Brier=0.1329，AUC=0.9577）。

5. 结果边界

GLM 单次参考版在 HE_DCNN 子集的准确率仅为 68.97%，说明不同来源间仍有明显差异。这些图像已多次用于方法开发和阈值选择，尚无独立最终测试集，患者独立性也未确认；100 张“正常来源”图片缺乏逐人的专项排除依据，其他肝病阴性样本较少。因此，当前分数属于探索性开发结果，估计概率尚未校准，不能解释为临床诊断性能。